



Universidade do Minho

Escola de Engenharia

Licenciatura em Engenharia Informática

Conceção de Modelos de Aprendizagem e Decisão

Aprendizagem e Decisão Inteligentes

Ano Letivo 2025/2026

Grupo 34

A106919 Eduardo Freitas Fernandes

A107326 Guilherme Santos da Costa

A106888 José Mário Raimundo Lima

A107375 Pedro Nuno de Bastos Pinho Costa

ADI

Índice

1. Introdução	2
2. <i>Production Dataset</i>	3
2.1. Observações	3
2.2. Análise Estatística	4
2.3. Tratamento de Dados	7
2.4. Modelos Desenvolvidos	8
2.4.1. Classificação (Árvores de Decisão)	9
2.4.2. Regressão Linear	11
2.5. Análise dos Resultados	13
2.5.1. Resultados das Árvores de Decisão	13
3. <i>AI Job Market Dataset</i>	14
3.1. Origem do <i>Dataset</i>	14
3.2. Observações	14
3.3. Análise Estatística	15
3.4. Exploração Contextual	17
3.5. Tratamento de Dados	21
3.5.1. Criação de Variáveis	21
3.5.2. Pré-processamento	21
3.6. Modelos Desenvolvidos	22
3.6.1. Clustering	22
3.6.1.1. Cenário 1 – k-Means com variáveis numéricas e binárias	22
3.6.1.2. Cenário 2 – k-Means com PCA	23
3.6.1.3. Cenário 3 – k-Means com seleção reduzida de variáveis	23
3.6.2. Regressão	24
3.6.2.1. Cenário 1 – Normalização Z-score	25
3.6.2.2. Cenário 2 – Normalização Min-max	26
3.6.2.3. Cenário 3 – Numeric Binner (demand_score)	27
3.6.2.4. Cenário 4 – Numeric Binner (years_of_experience)	28
3.6.2.5. Cenário 5 – PCA	29
3.7. Análise dos Resultados	29
3.7.1. Clustering	29
3.7.2. Regressão	30
4. Conclusão	31

1. Introdução

Este relatório descreve o trabalho desenvolvido no âmbito da unidade curricular de Aprendizagem e Decisão Inteligentes (ADI), do 3.º ano da Licenciatura em Engenharia Informática da Universidade do Minho, referente ao ano letivo 2025/2026.

O trabalho engloba duas tarefas distintas, abordadas em simultâneo com recurso à plataforma KNIME:

- **Production Dataset** – análise de um dataset de produção de energia em redes de distribuição, com desenvolvimento de modelos de classificação e regressão;
- **AI Job Market Dataset** – seleção e análise de um dataset do mercado de emprego em Inteligência Artificial, com conceção e otimização de diversos modelos de Machine Learning.

As secções seguintes detalham a exploração e preparação dos dados, os modelos desenvolvidos e a análise crítica dos resultados obtidos.

2. Production Dataset

2.1. Observações

O dataset atribuído diz respeito à produção de energia em redes de distribuição, contendo registos horários com informação meteorológica e de produção por diferentes tecnologias renováveis. A variável alvo é **Productions**, que classifica a taxa de produção em classes discretas.

O dataset é composto pelas seguintes variáveis:

Variável	Descrição
Date/Time	Timestamp horário do registo
Cogeneration (kWh)	Produção em unidades de cogeração
Wind (kWh)	Produção em unidades eólicas
Photovoltaics (kWh)	Produção em unidades fotovoltaicas
Hydro (kWh)	Produção em unidades hídricas
Other Technologies (kWh)	Produção noutras tecnologias
Distribution Network (kWh)	Produção total na rede de distribuição
temperature_2m (°C)	Temperatura exterior a 2 metros
relative_humidity_2m (%)	Humidade relativa a 2 metros
precipitation (mm)	Precipitação
rain (mm)	Pluviosidade
snowfall (cm)	Queda de neve
cloud_cover (%)	Cobertura de nuvens
Wind_Direction_10m / 100m	Direção do vento a 10 m e 100 m
wind_speed_10m / 100m (km/h)	Velocidade do vento a 10 m e 100 m
direct_radiation (W/m ²)	Radiação direta solar
shortwave_radiation (W/m ²)	Radiação de onda curta
diffuse_radiation (W/m ²)	Radiação difusa
direct_normal_irradiance (W/m ²)	Irradiância normal direta
terrestrial_radiation (W/m ²)	Radiação terrestre
Productions	Classe de taxa de produção (variável alvo)

Tabela 1: Variáveis do dataset de produção de energia.

2.2. Análise Estatística

A análise estatística foi realizada com recurso aos nós **Statistics**, **Data Explorer** e métricas de correlação (como **Rank Correlation**) no KNIME, permitindo caracterizar a distribuição das variáveis meteorológicas e energéticas, bem como identificar relações ocultas entre elas.



Figura 1: Estatísticas descritivas das variáveis numéricas do dataset.

Column	Exclude Column	Minimum	Maximum	Mean	Standard Deviation	Variance	Skewness	Kurtosis
RowID	☐	0	8782	4391	2535.578040605337	6429156	0	-1.2000000000000048
Wind (kWh)	☐	681.1875	1230015.0625	388584.90501236095	283428.1769142977	80331531468.96243	0.8166652934816366	-0.1620894226592477
Hydro (kWh)	☐	766.9375	56603.8125	23899.546936119874	17400.578530350558	302780133.19089675	0.3851752295386102	-1.2827216207932988
Other Technologies (kWh)	☐	27413.114750000008	143198.21743799996	79000.1908905589	24647.8816530251	607518069.9815313	-0.1665925809921839	-0.9472192804968658
Distribution Network (kWh)	☐	103745.429	1455571.6015	550491.5854790556	280664.60631436505	78772621237.59752	0.8444890232293326	-0.05561702499746094
temperature_2m (°C)	☐	-0.2	36.9	15.45302089930336	6.09135133744836	37.104561116233924	0.39238440909549804	0.08162526263423296
relative_humidity_2m (%)	☐	13	100	77.27256614761345	17.08800069268955	291.9997676733586	-0.7953835217429585	-0.09278366203497185
precipitation (mm)	☐	0.1	12.1	0.8953977272727275	1.407575686424567	1.961269313013591	3.34867508691191	14.778760711454016
rain (mm)	☐	0.1	12.1	0.8742953776775654	1.3916818127836434	1.9367782680327679	3.3826145157212655	15.114675200142395
snowfall (cm)	☐	0	0.49	0.00020356555822480712	0.008868540982126173	0.00007865101915165146	46.51787748900645	2241.8648677781134
cloud_cover (%)	☐	0	100	55.58707039734245	43.42088841996051	1885.3735511786608	-0.1994935942060736	-1.7551254238899012
wind_speed_10m (km/h)	☐	0	47.3	9.565380723501118	5.9924077487012495	35.90895062669478	1.2120133127992516	1.9151861151927065
wind_speed_100m (km/h)	☐	0	73.3	16.101389590702397	9.974380097736042	99.48825833411286	0.9479181268958952	1.2663794363843577
direct_radiation (W/m²)	☐	0	866	122.01880363452824	209.3047482067544	43808.47762189285	1.776999851003156	2.099435507745305
shortwave_radiation (W/m²)	☐	0	979	176.45555836920715	258.7140471629657	66932.95819944124	1.3943861547811491	0.7532253256189544
direct_normal_irradiance (W/m²)	☐	0	933	212.86210982290757	304.84428253072855	92930.03699167465	1.0735719484348163	-0.45791065124873936
terrestrial_radiation (W/m²)	☐	0	1256.6	323.1809385277011	404.8065428777059	163869.95638677146	0.8796163353250525	-0.6863083069393583

Figura 2: Exploração detalhada da distribuição das variáveis via Data Explorer.

As variáveis numéricas contínuas apresentam as seguintes características gerais:

- **temperature_2m (°C)** e **relative_humidity_2m (%)**: refletem uma grande amplitude térmica sazonal, com a temperatura a oscilar fortemente entre valores negativos (-0,2 °C) e picos de muito calor (36.9 °C);
- Variáveis de radiação solar (**shortwave**, **direct** e **diffuse**): apresentam uma assimetria natural muito acentuada, com medianas próximas de zero (devido aos períodos noturnos) e picos máximos elevados, o que dita a intermitência da energia fotovoltaica;
- **wind_speed_10m** e **wind_speed_100m**: velocidades do vento com distribuições típicas (enviadas à direita), essenciais para o acionamento das turbinas eólicas;
- Produção energética (**Wind**, **Photovoltaics**, **Hydro**): mostram um elevado desvio padrão, refletindo flutuações constantes de produção ditadas pelo estado do tempo e não por débitos contínuos.

As variáveis nominais e descritivas mostram:




Figura 3: Estatísticas descritivas das variáveis nominais e categóricas do dataset.

- A variável alvo **Productions** agrupa de forma discreta o estado da rede de distribuição de energia;
- Diversos atributos apresentam falhas na tipologia (necessitando de conversão de **String** para **Number**) ou dados nulos decorrentes de falhas de telemetria, o que motivará o tratamento de dados seguinte. No caso específico das variáveis de precipitação (**precipitation** e **rain**), os missing values foram assumidos como 0, uma vez que a ausência de registo é fisicamente compatível com ausência de precipitação.

Análise de correlação revelou redundâncias e algumas dependências lógicas fundamentais para a correta seleção de variáveis para a modelação:

- Identificaram-se fortes correlações lógicas entre a **precipitation (mm)** e a **rain (mm)**, bem como entre as três métricas de medição de radiação solar, indiciando sobreposição de informação;
- Observou-se uma forte correlação (sem significado físico) entre a variável **RowID** e as restantes variáveis do **dataset**. Por se tratar apenas de um índice automático sequencial, justificou-se a sua remoção prévia para não introduzir enviesamentos matemáticos (**data leakage**) nos classificadores.




Figura 4: Matriz de correlação de Spearman evidenciando dependências não-lineares.

2.3. Tratamento de Dados

A qualidade dos dados meteorológicos e de produção apresenta frequentemente falhas, provavelmente decorrentes de problemas nos sensores ou interrupções na telemetria. Por conseguinte, o pipeline de pré-processamento de dados estruturou-se em três eixos principais:

1. **Conversão de Tipos e Limpeza:** Utilização dos nós **String Replacer (Dictionary)** e **String to Number** para normalizar nomenclaturas textuais e garantir que todas as variáveis quantitativas se encontravam no formato numérico adequado (Integer ou Double) para os algoritmos de modelação.
2. **Engenharia de Variáveis (Feature Engineering):** Extração de componentes temporais cruciais a partir da coluna de data/hora transformada (como o mês, dia e hora) utilizando o nó **Extract Date&Time**. Estes metadados são essenciais para capturar o comportamento cíclico diário e sazonal da produção de energia renovável.
3. **Tratamento de Valores Omissos (Missing Values):** Como os dados representam séries temporais cronológicas, a simples eliminação de registos nulos criaria descontinuidade. Foram implementadas e validadas duas abordagens concorrentes em sub-metadados específicos:

- **Imputação por Média (com ou sem arredondamentos):** Substituição dos valores em falta pela média estatística global da respetiva coluna.
- **Imputação por Interpolação:** Técnica avançada e ideal para séries cronológicas contínuas, que estima o valor em falta baseando-se na tendência matemática e nos valores dos instantes imediatamente anteriores e posteriores.

O encadeamento completo e a arquitetura visual destas etapas e ramificações na plataforma KNIME é encontram-se documentados na Figura 5.




Figura 5: Workflow principal desenvolvido no KNIME para o Production Dataset, exibindo a segregação por metanós e ramificações.

2.4. Modelos Desenvolvidos

A infraestrutura de modelação preditiva para o **Production Dataset** dividiu-se na resolução de dois cenários distintos de Aprendizagem Supervisionada: Classificação (para prever o estado categórico da produção) e Regressão (para prever a potência contínua em kilowatts). Os dados foram geridos através do nó **Table Partitioner** (com uma divisão clássica de 70% para treino e 30% para teste), utilizando também ciclos de validação cruzada (**X-Partitioner** e **X-Aggregator**) para garantir a estabilidade estatística dos modelos.

2.4.1. Classificação (Árvores de Decisão)

O objetivo principal consistiu em prever a classe discreta da variável alvo *Productions*. Para isso, utilizou-se o algoritmo **Decision Tree Learner**, distribuído em paralelo dentro de duas grandes abordagens de tratamento de dados (**Uso de Média** e **Uso de Interpolação**). Em cada uma destas abordagens, foram desenvolvidos e avaliados três sub-cenários de testes experimentais:

- **Análise Inicial:** Implementação base do algoritmo utilizando a parametrização por omissão sobre os dados limpos, estruturada com partições de validação cruzada para medir o erro inicial de classificação e para saber qual/quais abordagens tinham uma capacidade consideravelmente inferior às outras para focar nas melhores;



Figura 6: Metanodo da análise inicial.

- **Segunda Análise:** Otimização do modelo através do ajuste manual de hiperparâmetros de poda (**pruning**) e critérios de paragem por tamanho mínimo das folhas, com vista a simplificar a árvore, reduzir o sobreajuste e confirmar que as duas abordagens que passaram pela fase de análise inicial têm qualidade para avançar para uma análise mais profunda;



Figura 7: Estrutura interna desenvolvida no KNIME para o sub-metanó de “Análise Inicial” utilizando a Árvore de Decisão.

- **Análise Avançada:** Na análise avançada fez-se uma comparação entre as diferentes combinações de inclusão/exclusão dos atributos relativos a precipitação e chuva, após isso procedeu-se a tentar inferir a direção do vento no caso de exclusão do campo de precipitação, visto que este tinha dado as melhores previsões.




Figura 8: Estrutura interna desenvolvida no KNIME para o sub-metanó de “Análise Inicial” utilizando a Árvore de Decisão.

2.4.2. Regressão Linear

Em paralelo com o cenário de classificação, foi desenhado um pipeline alternativo focado na modelação contínua de valores numéricos de potência:

- **Regressão Linear Múltipla:** Desenvolvida dentro do sub-metanó Regressões Lineares, este modelo teve como meta estimar quantitativamente o valor numérico total de Distribution Network (kWh). Utilizou como preditores independentes as variáveis climáticas contínuas (como as várias métricas de radiação, a temperatura e a velocidade do vento) para tentar traçar uma equação linear de débito energético.



Figura 9: Regressão Linear – estrutura do pipeline no KNIME.



Figura 10: Regressão Linear – estrutura do pipeline no KNIME.

2.5. Análise dos Resultados

2.5.1. Resultados das Árvores de Decisão

Para a análise inicial a interpolação teve resultados de 84%, 89% e 85% respetivamente para os modelos de cima para baixo. No caso em que usámos média os resultados foram significativamente melhores, tendo ambos 88%, 93% e 93% pela mesma ordem.

Quanto à segunda análise as duas abordagens de média tiveram os mesmos valores nos modelos em que não se usou **X-Partitioner** e quando se usou o mesmo obtivemos melhores resultados ao usar arredondamentos do que média certa, sendo os resultados 93,36% contra 93,31% no modelo de que se encontra mais acima no workflow e 93,26% contra 93,13% no outro. Face a estes dados decidimos avançar com uma análise mais profunda nos dois métodos de tratamento de valores nulos por média.

3. AI Job Market Dataset

3.1. Origem do Dataset

O dataset selecionado pelo grupo – **AI Jobs Market 2025/2026** – foi obtido a partir da plataforma Kaggle e reúne informação sobre 1500 ofertas de emprego na área da Inteligência Artificial, cobrindo múltiplos países, setores e perfis profissionais. O objetivo é analisar tendências salariais, requisitos de experiência e dinâmicas do mercado de trabalho em IA, com vista à conceção de modelos de regressão e clustering.

3.2. Observações

O dataset é composto por 1500 registos e 25 variáveis, sem valores omissos na versão original. As variáveis abrangem informação sobre o cargo, a empresa, a localização, o salário e indicadores de mercado:

Variável	Descrição
job_title	Título do cargo
job_category	Área da função (ex.: AI Engineering, Data Science)
experience_level	Nível de experiência requerido (Entry, Mid, Senior, Lead)
years_of_experience	Anos de experiência necessários
education_required	Habilitação mínima exigida
annual_salary_usd	Salário anual em USD (variável alvo da regressão)
salary_min/max_usd	Intervalo salarial mínimo e máximo
city / country	Localização da oferta
remote_work	Regime de trabalho (On-site, Hybrid, Fully Remote)
company_size	Dimensão da empresa (Startup, SME, Enterprise, Big Tech)
industry	Setor de atividade (12 setores)
required_skills	Competências técnicas exigidas (separadas por)
ai_salary_premium_pct	Prémio salarial face a funções equivalentes não-IA
demand_score	Índice de procura do cargo (0–100)
demand_growth_yoy_pct	Crescimento anual da procura (%)
benefits_score_10	Qualidade do pacote de benefícios (0–10)
is_senior	Indicador binário – cargo sénior
is_remote_friendly	Indicador binário – aceita trabalho remoto
is_llm_role	Indicador binário – cargo focado em LLMs
salary_tier	Classificação salarial em 5 categorias (Entry, Mid, Upper-Mid, Senior, Elite)

Tabela 2: Variáveis do dataset AI Jobs Market 2025/2026.

3.3. Análise Estatística

A análise estatística foi realizada com recurso aos nós **Statistics**, **Data Explorer**, **Value Counter**, **Linear Correlation** e **Rank Correlation** no KNIME, permitindo caracterizar a distribuição das variáveis e identificar relações entre elas.




Figura 11: Estatísticas descritivas das variáveis numéricas do dataset.

Numeric								
Nominal								
Data Preview								
Search:								
Column	Exclude Column	Minimum	Maximum	Mean	Standard Deviation	Variance	Skewness	
years_of_experience	☐	1	15	6.216000000000007	2.675216225760026	7.156781854569718	0.34203131077933696	
annual_salary_usd	☐	90000	384000	194891.99999999998	66506.82201285448	4423157374.249505	0.7210638202387722	
salary_min_usd	☐	90000	180000	135448.66666666664	24448.9508772827	597751199.0215701	-0.20054600651019072	
salary_max_usd	☐	180000	320000	257537.33333333337	39852.82220680808	1588247437.8474553	-0.41321843193649394	
ai_salary_premium_pct	☐	3	18	10.8582	4.029741758362777	16.23881863909272	-0.03967173080088745	
demand_score	☐	68	98	87.52333333333334	8.026315263766081	64.42173671336437	-0.786757311222892	
demand_growth_yoy_pct	☐	5	87.8	31.116333333333365	22.046343174938254	486.04124738714654	1.0421209806216838	
benefits_score_10	☐	6	9.8	7.897333333333328	1.1028464999674927	1.2162704024905489	0.0016083245508796398	
posting_year	☐	2025	2026	2025.58400000000017	0.49305787765111747	0.24310607071382434	-0.341185703931617	
posting_month	☐	1	12	3.968	3.2703882990277466	10.695439626417597	1.238733814401159	
is_senior	☐	0	1	0.49666666666666687	0.500155635106155	0.25015565932844125	0.013346980329061144	
is_remote_friendly	☐	0	1	0.7540000000000001	0.43082216573933163	0.18560773849232812	-1.1807151026625127	
is_lim_role	☐	0	1	0.218000000000000036	0.41302509183380465	0.17058972648432277	1.3673576137901813	
Showing 1 to 13 of 13 entries								

Figura 12: Exploração detalhada da distribuição das variáveis.

As variáveis numéricas contínuas apresentam as seguintes características gerais:

- `annual_salary_usd`: salários entre aproximadamente 90 000 e 400 000 USD, com concentração na faixa 100 000–250 000 USD;
- `demand_score`: distribuição concentrada acima de 60, com a maioria dos cargos a apresentar procura elevada;
- `years_of_experience`: maioritariamente entre 0 e 10 anos;
- `benefits_score_10`: concentrada entre 6 e 10, sem valores baixos relevantes.

As variáveis categóricas mostram:

- 12 categorias de `job_category`, com maior representação em AI Engineering;
- 12 setores de `industry`, com destaque para Finance e Technology;
- Distribuição equilibrada entre os regimes de `remote_work` (On-site, Hybrid, Fully Remote).

A análise de correlação revelou que `salary_min_usd` e `salary_max_usd` são altamente correlacionadas com `annual_salary_usd`, o que justifica a sua remoção antes da modelação para evitar data leakage.




Figura 13: Matriz de correlação de Pearson entre variáveis numéricas.




Figura 14: Matriz de correlação de Spearman entre variáveis.

3.4. Exploração Contextual

A exploração visual foi realizada com recurso a múltiplos gráficos no KNIME, permitindo identificar padrões e relações entre variáveis de forma intuitiva.

Salário por nível de experiência – O nível Lead (10+ anos) apresenta o salário médio mais elevado (235 000 USD), seguido do nível Senior (210 000 USD), Mid (175 000 USD) e Entry (150 000 USD), confirmando uma progressão salarial clara com a experiência.




Figura 15: Salário médio por nível de experiência.

Anos de experiência vs Salário – O scatter plot não revela uma correlação linear clara entre os anos de experiência e o salário, com grande dispersão em todos os níveis de experiência. Isto sugere que outros fatores (empresa, localização, categoria) têm maior influência no salário do que os anos de experiência isoladamente.




Figura 16: Anos de experiência vs salário anual, colorido por nível de experiência.

Salário por tamanho de empresa – A Big Tech (FAANG+) apresenta a maior amplitude e mediana salarial, seguida das empresas Enterprise. As Startups têm salários mais baixos e menos dispersos.




Figura 17: Distribuição salarial por tamanho de empresa.

Salário médio por país – Os EUA lideram com um salário médio de 225 000 USD, enquanto a Índia apresenta o valor mais baixo (135 000 USD). A maioria dos países europeus e asiáticos situa-se entre 160 000 e 200 000 USD.




Figura 18: Salário médio por país.

Demand Score vs Salário — Os dados concentram-se em valores de demand_score superiores a 60, sem uma tendência salarial clara associada ao score de procura. As diferentes categorias de emprego distribuem-se de forma semelhante ao longo do eixo salarial.




Figura 19: Demand score vs salário anual, colorido por categoria de emprego.

Distribuição por categoria de emprego — O AI Engineering representa a maior fatia do dataset, seguido de Data Science e Robotics. Categorias como Security e Research têm representação mais reduzida.




Figura 20: Distribuição de ofertas por categoria de emprego.

Prémio salarial AI por categoria — O prémio salarial face a funções equivalentes não-IA é relativamente uniforme entre categorias, situando-se entre 6% e 13%. A categoria de Data Science apresenta o valor mais baixo e Architecture e Business os valores mais elevados.



Figura 21: Prémio salarial AI médio por categoria de emprego.

Benefícios vs Salário – Não existe correlação visível entre a qualidade dos benefícios e o salário, com os dados distribuídos uniformemente acima de um score de benefícios de 6.




Figura 22: Score de benefícios vs salário anual.

Funções LLM por indústria – Automotive, Finance e Government lideram em número de funções LLM, enquanto Consulting tem a menor presença. A distribuição é relativamente equilibrada entre setores.




Figura 23: Número de funções LLM por setor de indústria.

Crescimento de procura por categoria – ML Operations destaca-se com um crescimento anual de procura muito acima das restantes categorias (52%), seguido de AI Engineering (40%). As restantes categorias apresentam crescimentos entre 15% e 31%.




Figura 24: Crescimento anual de procura (%) por categoria de emprego.

3.5. Tratamento de Dados

3.5.1. Criação de Variáveis

Antes do pré-processamento foram criadas três variáveis adicionais:

- **salary_range**: amplitude salarial calculada como `salary_max_usd - salary_min_usd`, capturando a variabilidade salarial de cada oferta;
- **num_skills**: número de competências técnicas listadas em `required_skills`, contadas pelo separador `|`;
- **exp_mismatch**: indicador de desajuste entre o nível de experiência declarado e os anos exigidos – classifica como “Exigente” cargos Entry com mais de 2 anos, Mid com mais de 5 anos ou Lead com menos de 8 anos.

3.5.2. Pré-processamento

O pré-processamento foi implementado no KNIME com a seguinte sequência de nós:




Figura 25: Pipeline de pré-processamento implementado no KNIME.

1. **Numeric Outliers** – detecção e substituição de outliers em `annual_salary_usd` e `demand_score` pelo método IQR com multiplicador $k=1,5$;
2. **Missing Value** – imputação dos valores em falta: média para variáveis numéricas (Float e Integer) e moda para variáveis categóricas (String);
3. **Column Filter** – remoção de colunas irrelevantes para a análise: `job_id`, `job_title`, `required_skills`, `salary_min_usd`, `salary_max_usd` e `city`;
4. **One to Many** – codificação das variáveis categóricas em colunas binárias (*dummy variables*): `experience_level`, `education_required`, `remote_work`, `company_size`, `industry` e `job_category`.

3.6. Modelos Desenvolvidos

3.6.1. Clustering

O clustering foi realizado com o algoritmo **k-Means**, testando três cenários distintos de pré-processamento, com o objetivo de identificar segmentos naturais no mercado de emprego em IA. A qualidade dos clusters foi avaliada através do **Coefficiente de Silhouette**.

3.6.1.1. Cenário 1 – k-Means com variáveis numéricas e binárias

As variáveis selecionadas pelo **Column Filter** foram: `years_of_experience`, `annual_salary_usd`, `ai_salary_premium_pct`, `demand_score` e `is_llm_role`. Após normalização Z-score, foram testados $k=2$, $k=3$ e $k=4$:

k	Silhouette médio
2	0,325
3	0,256
4	0,248

Tabela 3: Resultados do clustering – Cenário 1.




Figura 26: Workflow do Cenário 1 de clustering com as variáveis selecionadas.

3.6.1.2. Cenário 2 – k-Means com PCA

As mesmas variáveis do Cenário 1 foram submetidas a normalização Z-score, seguida de redução de dimensionalidade por **PCA** com 3 componentes principais. Este cenário obteve o melhor Silhouette geral, com k=2:

k	Silhouette médio
2	0,332
3	0,286
4	0,287

Tabela 4: Resultados do clustering – Cenário 2 (com PCA).




Figura 27: Workflow do Cenário 2 de clustering com PCA (3 dimensões).

3.6.1.3. Cenário 3 – k-Means com seleção reduzida de variáveis

Restringindo o clustering às três variáveis numéricas mais relevantes – `annual_salary_usd`, `years_of_experience` e `demand_score` –, foram testados mais valores de k. O melhor resultado foi partilhado entre k=4 e k=5 (Silhouette = 0,288), optando-se por k=4 pela sua maior simplicidade interpretativa:

k	Silhouette médio
2	0,280
3	0,261
4	0,288
5	0,288
6	0,265

Tabela 5: Resultados do clustering – Cenário 3.




Figura 28: Workflow do Cenário 3 de clustering com seleção reduzida de variáveis.

O melhor resultado foi obtido no Cenário 3 com $k=4$, onde os clusters identificados apresentaram os seguintes perfis:

Cluster	Perfil
Baixa Procura e Baixo Salário	Salário abaixo da média, pouca experiência e demand_score muito reduzido – perfis com menor atratividade no mercado
Elite Salarial	Salário muito acima da média, experiência intermédia e demand_score elevado – posições de topo bem remuneradas
Especialistas LLM	Salário médio-baixo, pouca experiência mas demand_score alto – perfis júnior em áreas de grande procura como LLMs
Experientes Subvalorizados	Muitos anos de experiência mas salário abaixo do esperado – profissionais seniores em funções menos valorizadas

Tabela 6: Perfis dos clusters identificados no Cenário 3 com $k=4$.

3.6.2. Regressão

O objetivo da regressão é prever o `annual_salary_usd` com base nas restantes variáveis. Foram testados cinco cenários de pré-processamento, cada um com três algoritmos: **Árvore de Regressão Simples**, **Regressão Linear** e **Random Forest**. Os dados foram divididos em 80%

treino e 20% teste (Cenários 1 e 2) ou 70% treino e 30% teste (Cenários 3, 4 e 5) através do nó **Table Partitioner**.

3.6.2.1. Cenário 1 – Normalização Z-score

Normalização das variáveis de entrada pelo método Z-score, excluindo o target `annual_salary_usd`.



Figura 29: Cenário 1 – Regressão com normalização Z-score.

3.6.2.2. Cenário 2 – Normalização Min-max

Normalização das variáveis de entrada pelo método Min-max, excluindo o target `annual_salary_usd`.




Figura 30: Cenário 2 – Regressão com normalização Min-max.

3.6.2.3. Cenário 3 – Numeric Binner (demand_score)

Discretização do demand_score em três intervalos: Baixa Procura (<50), Média Procura (50–75) e Alta Procura (>75).




Figura 31: Cenário 3 – Regressão com Numeric Binner aplicado ao demand_score.

3.6.2.4. Cenário 4 – Numeric Binner (years_of_experience)

Discretização do years_of_experience em três grupos: Júnior (<3 anos), Mid (3–7 anos) e Sênior (>7 anos).




Figura 32: Cenário 4 – Regressão com Numeric Binner aplicado aos anos de experiência.

3.6.2.5. Cenário 5 – PCA

Redução de dimensionalidade com PCA após normalização Z-score, antes da modelação.




Figura 33: Cenário 5 – Regressão com PCA.

3.7. Análise dos Resultados

3.7.1. Clustering

O melhor Silhouette obtido foi de 0,332 no Cenário 2 (com PCA, $k=2$), seguido do Cenário 1 (0,325, $k=2$) e do Cenário 3 (0,288, $k=4$). Os valores moderados indicam que o mercado de emprego em IA não forma segmentos completamente discretos – as diferenças entre perfis são graduais. Ainda assim, os clusters identificados no Cenário 3 com $k=4$ têm interpretação clara: **Baixa Procura e Baixo Salário**, **Elite Salarial**, **Especialistas LLM** e **Experientes Subvalorizados**.

3.7.2. Regressão

Os resultados dos cinco cenários de regressão são resumidos na tabela seguinte:

Cenário	Modelo	R ²	MAE (USD)	RMSE (USD)
1 – Z-score	Árvore Simples	0,098	42 113	58 485
	Regressão Linear	0,841	18 314	24 541
	Random Forest	0,771	23 969	29 489
2 – Min-max	Árvore Simples	0,097	42 166	58 531
	Regressão Linear	0,839	18 481	24 683
	Random Forest	0,771	23 988	29 484
3 – Binner demand_score	Árvore Simples	-0,037	44 847	62 448
	Regressão Linear	0,808	18 734	26 848
	Random Forest	0,741	24 722	31 191
4 – Binner years_exp	Árvore Simples	-0,044	41 408	59 967
	Regressão Linear	0,807	18 637	26 906
	Random Forest	0,741	24 463	31 236
5 – PCA	Árvore Simples	0,439	–	–
	Regressão Linear	0,797	–	–
	Random Forest	0,727	–	–

Tabela 7: Resultados comparativos dos modelos de regressão nos cinco cenários.

A **Regressão Linear** obteve o melhor desempenho geral, com $R^2=0,841$ no Cenário 1 (Z-score), explicando 84% da variância do salário. Os cenários com Numeric Binner (3 e 4) degradaram ligeiramente o desempenho ($R^2 \approx 0,808$ e $0,807$), confirmando que a discretização de variáveis contínuas perde granularidade.

O **Random Forest** manteve desempenho consistente entre cenários ($R^2 \approx 0,741-0,771$), mas inferior à Regressão Linear, sugerindo que as relações no dataset são predominantemente lineares.

A **Árvore de Regressão Simples** obteve fraco desempenho nos Cenários 1 a 4 ($R^2 < 0,10$ ou negativo), sendo a exceção o Cenário 5 com PCA ($R^2=0,439$), onde a redução dimensional aparentemente favoreceu a simplicidade do modelo.

O Cenário 5 com **PCA** apresentou resultados intermédios – a Regressão Linear desceu para $R^2=0,797$ face aos $0,841$ do Z-score, indicando que a compressão dimensional elimina alguma informação relevante para a previsão salarial.

4. Conclusão

O trabalho permitiu aplicar, na prática, técnicas de pré-processamento, clustering e regressão sobre dois datasets distintos, com recurso ao KNIME.

No **Production Dataset**, foram desenvolvidos modelos de classificação com Árvores de Decisão e de regressão linear para prever a produção energética, explorando duas estratégias de imputação de valores em falta e incorporando variáveis temporais derivadas da data/hora.

No **AI Job Market Dataset**, o clustering com k-Means identificou quatro segmentos interpretáveis no mercado de emprego em IA (Cenário 3, $k=4$, Silhouette=0,288). Na regressão, a **Regressão Linear** foi o modelo com melhor desempenho em todos os cenários, atingindo $R^2=0,841$ com normalização Z-score, confirmando que as relações entre as variáveis e o salário são predominantemente lineares. A discretização via Numeric Binner degradou ligeiramente os resultados, e o PCA beneficiou sobretudo a Árvore de Regressão Simples.

Em ambas as tarefas, ficou evidente que a qualidade do pré-processamento tem um impacto direto no desempenho dos modelos, e que a comparação sistemática de cenários é essencial para identificar a abordagem mais adequada a cada problema.